

Caso de Estudio: Predicción y Clasificación de Composición Corporal

Contexto del Negocio

Una prestigiosa cadena de gimnasios de alto rendimiento busca digitalizar y optimizar sus evaluaciones físicas. Actualmente, calcular el porcentaje de grasa corporal real (`BodyFat`) requiere un pesaje hidrostático (bajo el agua), un método costoso, lento y 除去 incómodo para los clientes.

El equipo de entrenadores ha recolectado datos antropométricos simples de los miembros (peso, altura y perímetros corporales con cinta métrica). Tu objetivo como Científico de Datos es desarrollar modelos analíticos que permitan estimar la grasa corporal y diagnosticar problemas de salud sin necesidad de usar el equipo especializado.

El Dataset

Los alumnos trabajarán con una muestra del célebre *Body Fat Dataset*. Cada registro representa a un usuario entrenado con las siguientes variables:

- **Densidad (`Density`):** Densidad corporal determinada por pesaje subacuático (g/cm^3).
 - **Grasa Corporal (`BodyFat`):** Porcentaje de grasa corporal real (Variable objetivo continua).
 - **Variables Predictoras Anatómicas:** `Age` (Edad), `Weight` (Peso en lbs), `Height` (Altura en pulgadas), y perímetros en centímetros de: `Neck` (Cuello), `Chest` (Pecho), `Abdomen`, `Hip` (Cadera), `Thigh` (Muslo), `Knee` (Rodilla), `Ankle` (Tobillo), `Biceps`, `Forearm` (Antebrazo) y `Wrist` (Muñeca).
-

Entregables y Retos del Alumno

Fase 1: Análisis Exploratorio de Datos (EDA)

1. **Matriz de Correlación:** Identificar visualmente cuáles son las tres medidas anatómicas que tienen mayor relación lineal con el porcentaje de `BodyFat`.
2. **Detección de Anomalías:** Analizar si existen problemas de consistencia entre las variables `Weight` y `Height` versus los perímetros medidos.

Fase 2: Reto de Regresión (Predicción Continua)

El departamento médico necesita la cifra exacta de grasa corporal del cliente.

1. **Modelo Línea Base:** Entrenar una **Regresión Lineal Múltiple** utilizando todas las variables anatómicas para predecir `BodyFat`.
2. **Modelos Avanzados:** Entrenar un **Random Forest Regressor** y un **XGBoost Regressor** con los mismos predictores.
3. **Evaluación:** Comparar los tres modelos mediante las métricas **MAE** (Error Absoluto Medio) y $\sqrt{R^2}$. Determinar cuál algoritmo comete menos error en kilogramos/porcentaje de grasa.
4. **Importancia de Variables:** Extraer el atributo `feature_importances_` de los árboles y compararlo con los coeficientes de la Regresión Lineal. ¿Coinciden en cuál es el músculo/zona clave?

Fase 3: Reto de Clasificación (Diagnóstico Automatizado)

El departamento de marketing quiere automatizar alertas de salud en la aplicación móvil para usuarios con niveles altos de grasa corporal.

1. **Ingeniería de Características:** Crear una nueva variable binaria llamada `High_Risk`. Asignar un valor de 1 si `BodyFat > 25%` (umbral de riesgo de obesidad), y 0 si es menor o igual.
2. **Modelado:** Entrenar una **Regresión Logística**, un **Random Forest Classifier** y un **XGBoost Classifier** para predecir la etiqueta `High_Risk`. (Nota: Deben eliminar las columnas originales `BodyFat` y `Density` del conjunto de entrenamiento).
3. **Evaluación Clínica:** Construir la **Matriz de Confusión** de cada modelo. Explicar cuál modelo minimiza los *Falsos Negativos* (clientes en riesgo no detectados por el sistema). Evaluar el desempeño general usando la métrica **F1-Score**.

Preguntas de Reflexión para la Defensa del Caso

- ¿Por qué es crítico eliminar `Density` y `BodyFat` al entrenar los modelos de la Fase 3?
 - Si un entrenador solo tiene tiempo de tomar una sola medida con la cinta métrica, ¿cuál zona del cuerpo debería medir según los modelos?
 - ¿Qué ventajas demostraron los modelos basados en árboles (Random Forest/XGBoost) sobre los modelos lineales tradicionales en este problema?
-